Analýza návštěvnosti památek v Jihomoravském kraji a Praze

Předmět: Práce s daty
Autoři: Marek Maněk
Vyučující: Ing. Mgr. Michal Jeřábek, Ph.D.
Repozitář projektu: [URL_TVÉHO_GITHUB_REPOZITÁŘE]

1. Úvod a cíl projektu

Tato semestrální práce analyzuje návštěvnost památek v Jihomoravském kraji a Praze na základě otevřených dat. Cílem je identifikovat faktory ovlivňující návštěvnost, porovnat dopady pandemie covidu-19 a vizualizovat trendy v cestovním ruchu napříč odlišně vymezenými regiony. Výstupy analýzy jsou zároveň prezentovány formou moderního webového reportu.

1.1 Výzkumné otázky

1. Jaký byl celkový vývoj návštěvnosti památek v obou regionech v čase?
2. Jaké byly dopady pandemie covidu-19 v letech 2020–2021 a jak probíhalo zotavení?
3. Které památky jsou v každém regionu nejpřitažlivější?
4. Jak se liší koncentrace návštěvníků do nejnavštěvovanějších objektů v Praze oproti Jihomoravskému kraji?

2. Zdroj dat

2.1 Popis datasetu

- **Zdroj:** Agregované statistiky návštěvnosti turistických cílů (NIPOS / Tourdata)
- **Období:** 2019–2025
- **Lokalita:** Jihomoravský kraj, Hlavní město Praha
- **Počet záznamů:** 322 (po vyčištění a transformaci)
- **Počet atributů:** 5 (finální vyčištěné sloupce)

2.2 Způsob získání dat

Data byla získána z oficiálních reportů návštěvnosti ve formátu XLSX pro jednotlivé kraje. Každý záznam v původních tabulkách představoval roční vývoj návštěvnosti konkrétního památkového objektu ve specifikovaném kraji.

3. Datový slovník a čištění

Proces čištění dat transformoval původní široký formát (roky jako sloupce) na relační formát vhodný pro analýzu, skládající se z 5 high-value sloupců. Během čištění byly odstraněny agregační řádky, textová metadata a neúplné záznamy.

Numerické sloupce (2)

Sloupec	Typ	Popis	Příklad
Návštěvnost	int	Celkový počet návštěvníků objektu	328477
Rok	int	Rok, za který jsou data evidována	2025

Kategorické a textové sloupce (3)

Sloupec	Typ	Popis	Příklad
Název	string	Oficiální název památky	Státní zámek Lednice
Kraj	category	Územní příslušnost	Jihomoravský kraj
webové stránky	string	URL identifikátor objektu	www.zamek-lednice.com

4. Kvalita dat a problémy

4.1 Identifikované problémy

4.1.1 Nekonzistentní chybějící hodnoty:

V původních tabulkách se pro označení chybějících dat střídaly znaky jako tečka (`.`) a křížek (`x`). Tyto znaky způsobovaly, že celý sloupec s roční návštěvností byl datově interpretován jako text (object) namísto čísla.

4.1.2 Skryté agregační mezisoučty:

Data obsahovala vložené součtové řádky za jednotlivé okresy. Pokud by nebyly odfiltrovány, vykazoval by dataset téměř dvojnásobnou celkovou návštěvnost.

4.1.3 Extrémní odlehlé hodnoty (Outliery):

Pražský hrad dosahuje návštěvnosti přes 2,5 milionu osob ročně, což představuje masivní outlier vychylující průměrné statistiky v pražském regionu směrem nahoru.

4.2 Provedené opravy

1. Ignorování úvodních textových metadat při načítání (`skiprows`).
2. Odstranění všech řádků obsahujících klíčová slova „Celkem Okres“ nebo „Okres “.
3. Sjednocení znaků `.` a `x` na systémovou hodnotu `NaN`.
4. Přetypování sloupců s návštěvností na numerický formát (`to_numeric`).
5. Transformace dat ze širokého do dlouhého formátu pomocí funkce `pd.melt`.

4.3 Výsledek čištění

Fáze	Počet záznamů	Počet sloupců
Původní data (široký formát)	~70 památek	9
Po čištění a transformaci (melt)	322	5

5. Metodologie zpracování a Tech Stack

5.1 Použité nástroje (Tech Stack)

- **Python 3.14+** – jádro pro zpracování dat a automatizaci
- **Pandas** – manipulace, čištění a relační transformace dat
- **NumPy** – matematické operace a ošetření chybějících hodnot
- **Matplotlib** – generování analytických grafů a vizualizací
- **HTML5 & Tailwind CSS v4** – tvorba responzivního webového reportu (`index.html`) v redakčním stylu (editorial design)

5.2 Postup zpracování

```
JM_2019-25.xlsx & PR_2019-25.xlsx
↓
[1. Načíst Excel soubory přes pd.read_excel s úpravou skiprows]
↓
[2. Odfiltrovat agregační mezisoučty a prázdné hodnoty]
↓
[3. Nahradit nestandardní znaky (. a x) za NaN a přetypovat]
↓
[4. Sloučit a transformovat data pomocí pd.melt]
↓
[5. Generovat agregace a exportovat zakladni_statistiky.csv]
↓
[6. Vytvořit vizualizace přes Matplotlib]
↓
vystupy/vycistena_data.csv (finální dataset)
vystupy/*.png (vygenerované grafy)
index.html (webová prezentace výsledků)
```

5.3 Matematický aparát

Meziroční procentuální změna:
Kvantifikace rychlosti poklesu či růstu trhu byla počítána vzorcem:
`Změna = ((Návštěvnost[t] – Návštěvnost[t-1]) / Návštěvnost[t-1]) × 100`

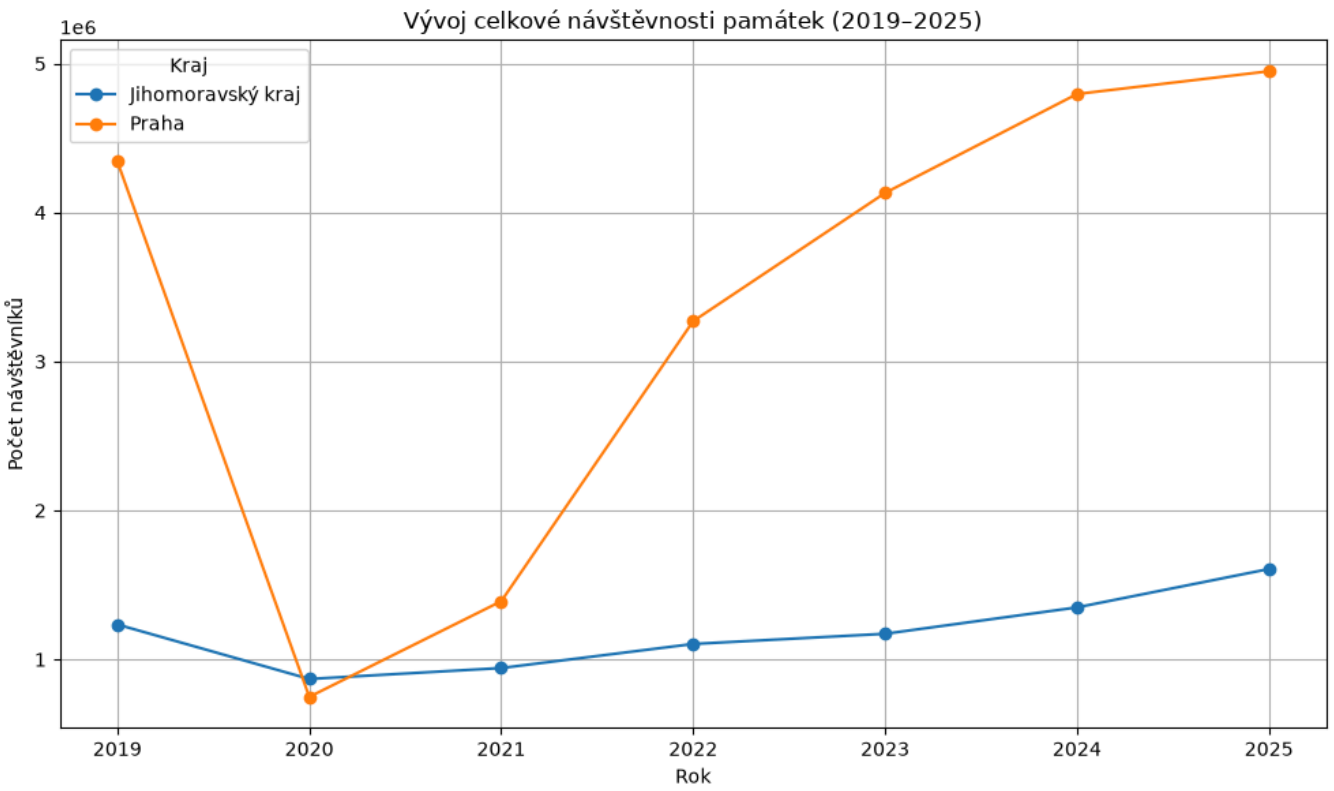
Kumulativní podíl návštěvnosti (Koncentrace):
Pro vyhodnocení Paretova pravidla v turismu:
`Kumulativní podíl = (Σ návštěvnosti seřazených památek / Celková návštěvnost regionu) × 100`

6. Výsledky

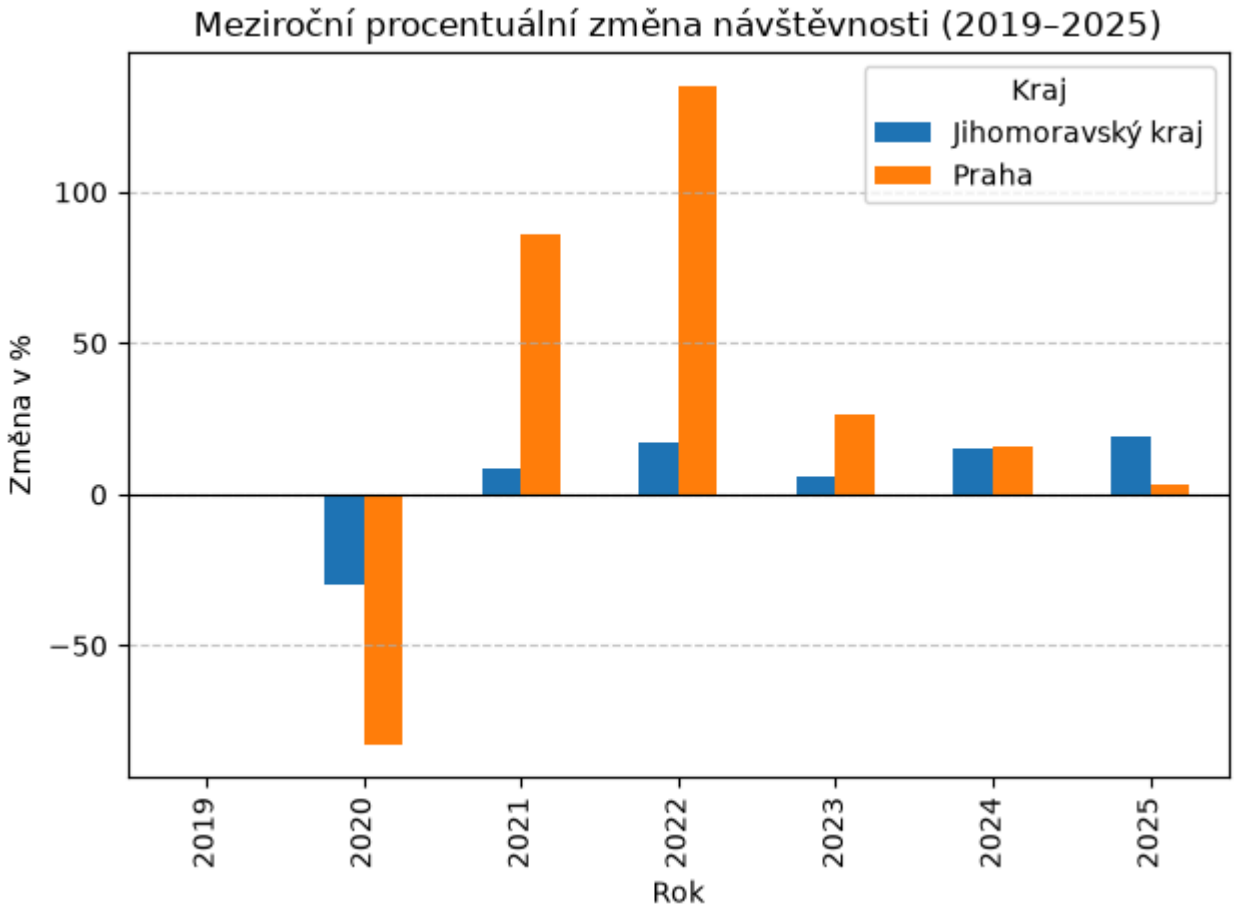
6.1 Základní statistiky (Souhrn 2019–2025)

Metrika	Jihomoravský kraj	Praha
Průměrná návštěvnost jedné památky	42 450	186 035
Medián návštěvnosti	23 888	46 817
Maximum (Nejnavštěvovaný objekt)	389 620	2 551 240

6.2 Vizualizace

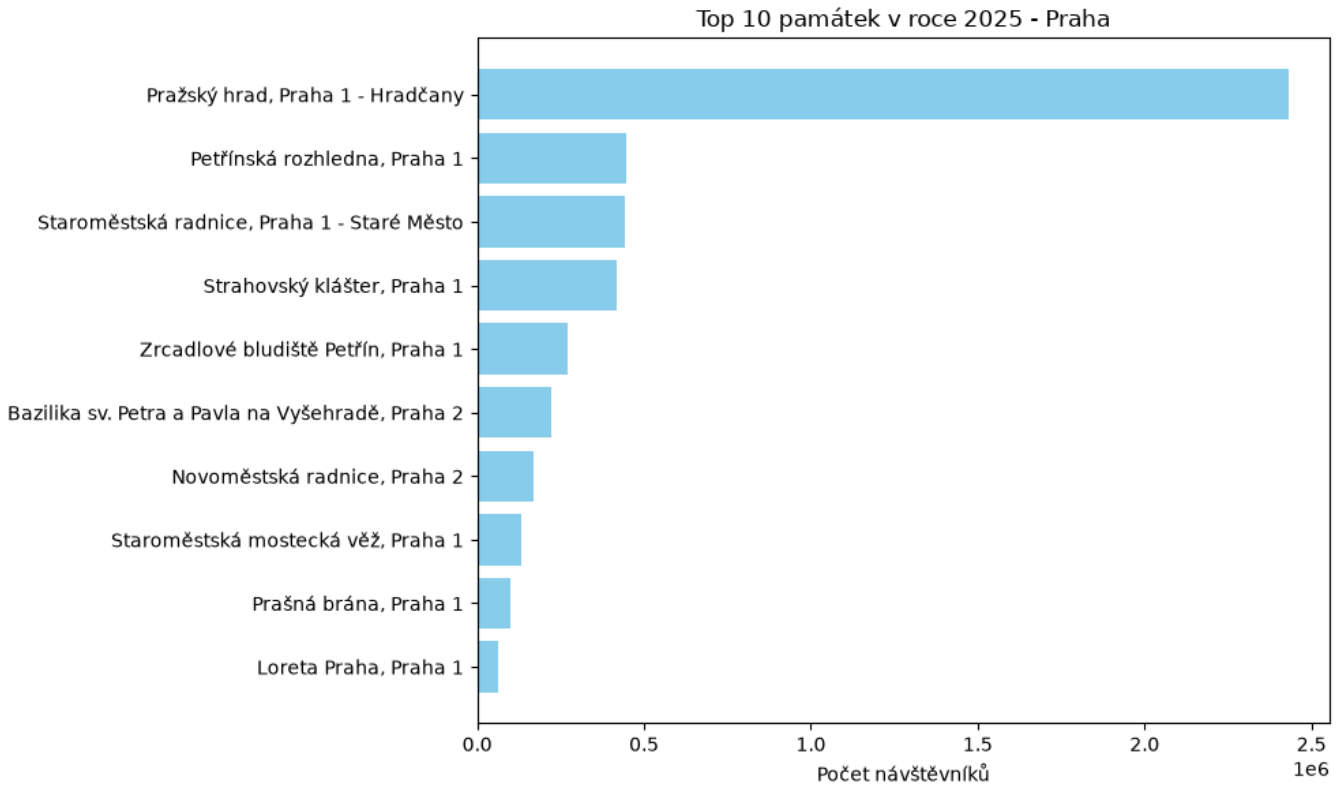


Graf 1: Vývoj celkové návštěvnosti památek (2019–2025). Spojnicový graf znázorňuje absolutní propad cestovního ruchu v roce 2020 a následný postupný proces zotavení v obou krajích.

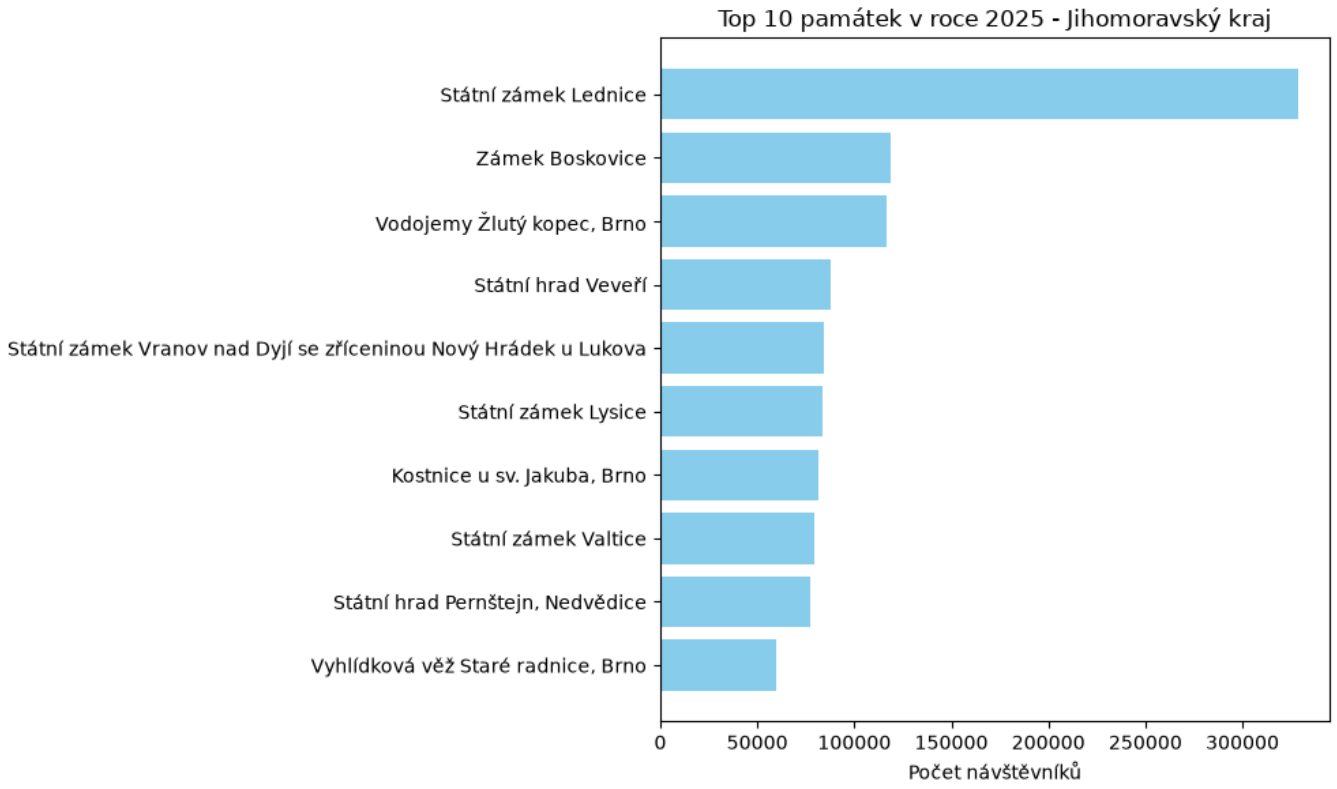


Graf 2: Meziroční procentuální změny. Sloupcový graf kvantifikuje šok z pandemie a ukazuje, který z regionů

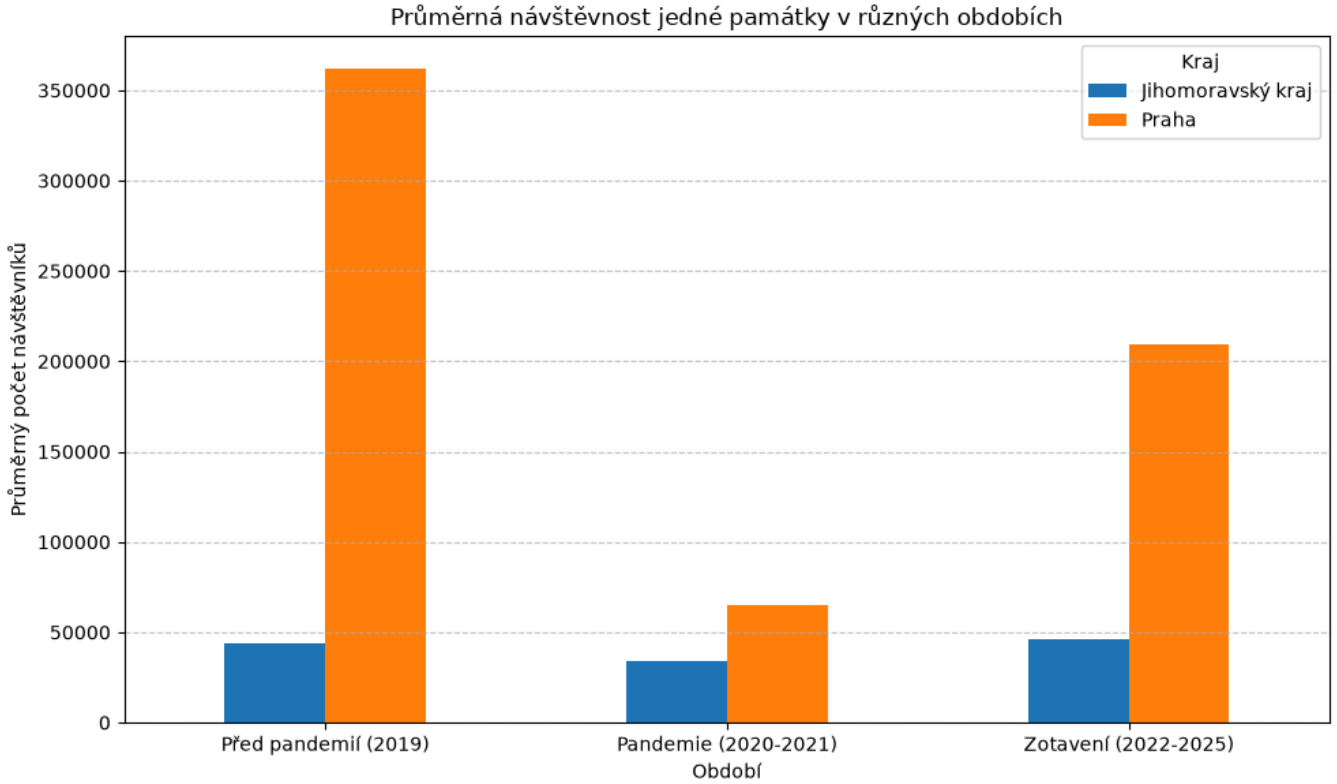
zaznamenal hlubší pád a který dynamičtější návrat turistů.



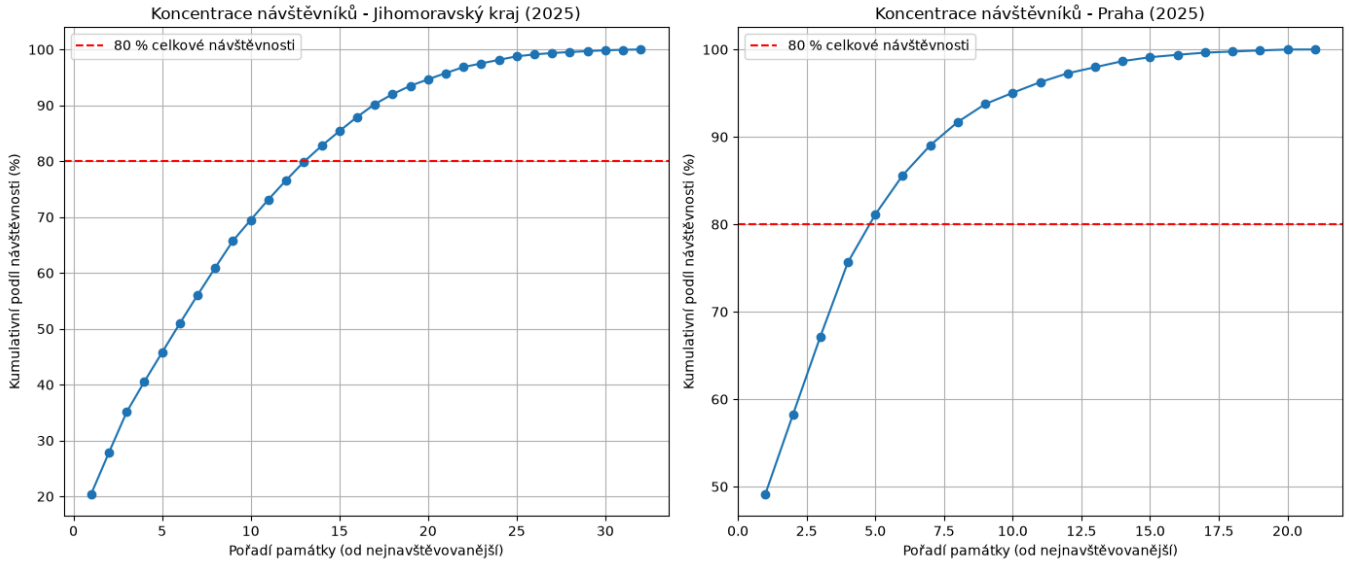
Graf 3: Žebříček deseti nejnavštěvovanějších památek v Praze (2025). Horizontální sloupcový graf ukazuje absolutní dominanci Pražského hradu v metropoli a výrazný odstup ostatních památek.



Graf 4: Žebříček deseti nejnavštěvovanějších památek v Jihomoravském kraji (2025). Na jižní Moravě vede žebříček návštěvnosti Státní zámek Lednice, trh je zde však rozložen podstatně rovnoměrněji.



Graf 5: Průměrná návštěvnost v klíčových obdobích. Porovnání tří fází trhu: předpandemické výkonnosti (2019), vlivu restrikcí (2020–2021) a aktuálního stavu zotavení (2022–2025).



Graf 6: Geografická a objektová koncentrace návštěvníků. Křivky kumulativního podílu dokazují, jak malý počet památek generuje drtivou většinu turistické zátěže (v Praze je tento jev výraznější).

7. Diskuze

7.1 Hlavní zjištění

- **Rozdílná struktura trhu:** Praha je silně centralizovaná kolem jedné primární památky (Pražský hrad), zatímco Jihomoravský kraj disponuje rovnoměrněji rozloženou sítí památek.
- **Elasticita a covid-19:** Metropolitní turismus v Praze, vysoce závislý na zahraničních hostech a letectví, zaznamenal během pandemie podstatně tvrdší propad než Jihomoravský kraj, který se opřel o domácí turistiku.

- **Paretovo pravidlo:** Graf koncentrace prokázal, že v obou regionech obslouží naprostou většinu turistů nejvyšších 20 % zkoumaných objektů.

7.2 Omezení analýzy

- **Časové období:** Analýza pokrývá primárně roky zasažené globální pandemií, chybí širší období stabilního růstu před rokem 2019.
- **Nesrovnatelnost celků:** Praha těží z masivní tranzitní dostupnosti na minimálním prostoru, zatímco JMK je plošná destinace.
- **Metodika počítání:** Některé objekty evidují i průchody otevřeným areálem, jiné vykazují striktně prodané vstupenky do expozic.

8. Závěr

Analýza agregovaného datasetu návštěvnosti v letech 2019–2025 ukázala, že pandemický šok zásadním způsobem ovlivnil chod památkových objektů, přičemž regiony závislé na mezinárodním turismu utrpěly hlubší ztráty. Data prokázala silnou koncentraci návštěvníků do úzké skupiny nejznámějších objektů napříč oběma kraji. Projekt demonstruje kompletní postup datové analýzy v Pythonu – od načítání problematických excelových tabulek, přes jejich relační čištění, agregaci, až po finální interpretaci metrik, vizualizaci a publikaci prostřednictvím moderního webového rozhraní.

9. Přílohy

9.1 Struktura projektu

```
Semestralni_prace/
├── index.html            # Webová prezentace výsledků (Tailwind CSS v4)
├── dokumentace.md        # Kompletní dokumentace projektu
├── analyza_pamatek.py    # Načtení, čištění a transformace
├── analyza_grafy.py      # Meziroční změny a žebříčky
├── analyza_dokonceni.py  # Kumulativní podíly a analýza období
├── JM_2019-25.xlsx       # Vstupní data JMK
├── PR_2019-25.xlsx       # Vstupní data Praha
└── vystupy/
    ├── vycistena_data.csv
    ├── zakladni_statistiky.csv
    └── *.png             # Vygenerované grafy
```

9.2 Výstupy

- `index.html` – Responzivní webový report v redakčním designu s prokliky na GitHub a stažení dat.
- `vystupy/vycistena_data.csv` – Vyčištěný centrální dataset ve strukturovaném formátu.
- `vystupy/zakladni_statistiky.csv` – Statistiky (průměry, mediány).
- `vystupy/*.png` – 6 exportovaných analytických vizualizací v tiskové kvalitě.